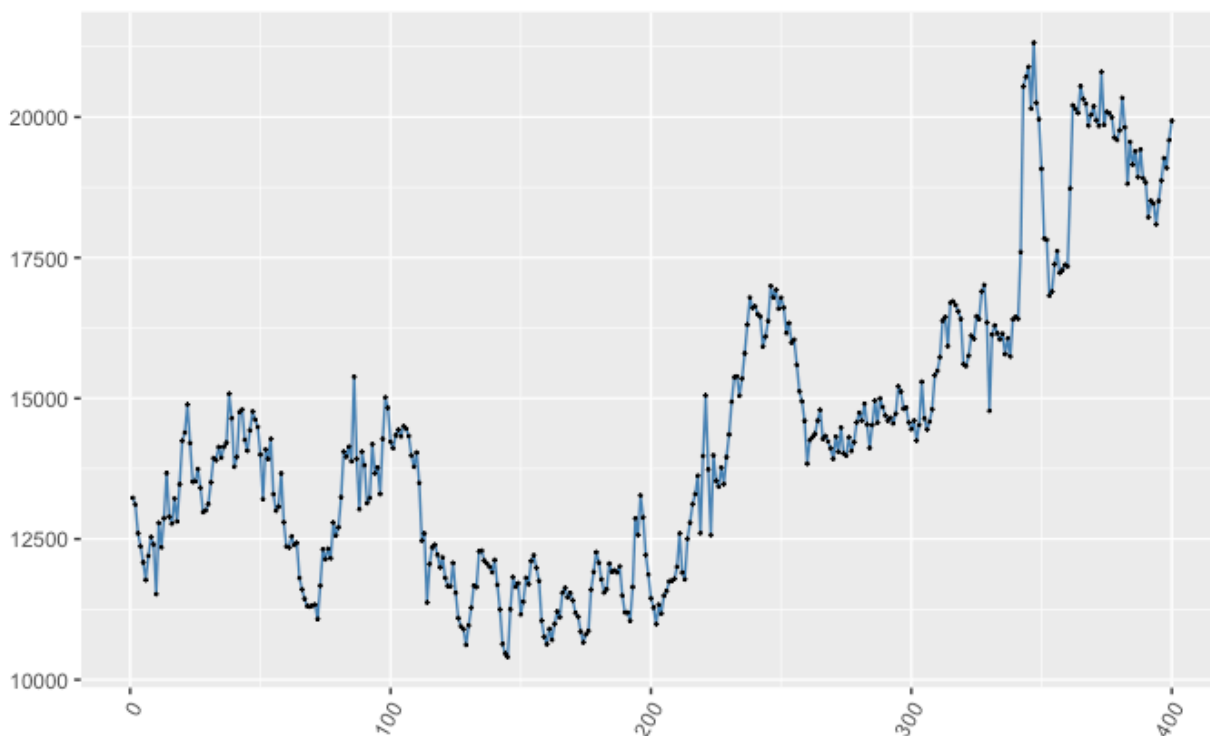


Praktični zadatak


Zadatak 7

Eleonora Detić, 1191241491



Analiza vremenskog niza

Prvi korak je grafički prikazati put vremenskog niza za dane podatke koristeći paket ggplot2 programskog jezika R. Zumirajući graf na nekoliko pojedinačnih intervala, uočila sam da bi mogla postojati sezonalna komponentu na dvotjednoj razini (svakih 14 mjerjenja). Lako se vidi da vremenski niz nije homogen jer uočavamo sve veću vrijednost podataka kroz vrijeme. Dakle, naslućujem i pozitivan trend.




Slika 1. Prikaz zumiranog vremenskog niza s ciljem utvrđivanje sezonalne komponente

Transformacija podataka

Trend sam procijenila i uklonila prilagodbom polinoma drugog stupnja koja se pokazala dosta slična prilagodbi polinomom trećeg stupnja.

$$y(t) = 14120 + -28.5 \cdot t + 0.11 \cdot t^2$$




Slika 2. Prilagodba trenda polinomom

Uklanjanjem trenda i komponente sezonalnosti koju sam procijenila direktnom procjenom, dobivam podatke kojima nastojim prilagoditi model.


Nakon micanja trenda i sezonalnosti, transformirani podaci variraju između vrijednosti -2000 i 2000, pri čemu je prisutno nekoliko stršćih vrijednosti.

U nastavku prikazujem grafove ACF i PACF funkcija. Iz PACF grafa mogu naslutiti dobru prilagodbu AR(1) modelu, dok iz ACF grafa mogu naslutiti dobru prilagodbu MA modelu višeg reda, no u zadatku je ograničenje $q \leq 3$ te se zato odlučujem za MA(3) model što kasnije potvrđujem i AIC kriterijem.


Budući da mogu uočiti i odstupanje u varijanci, npr. za podatke između 100 i 200 ono nije toliko veliko, no između 200 i 250 vidimo nagli skok, GARCH(1,1) bi također mogao biti dobar fit.




Slika 3. Prikaz vremenskog niza bez trenda i komponente sezonalnosti



Slika 4. Prilagodba modela transformiranim podacima



Slika 5. Prikaz ACF funkcije



Slika 6. Prikaz PACF funkcije

Prilagodba modela

Koristeći Yule - Walker proceduru, najbolji model je AR(1), a koristeći AIC kriterij najbolji model je MA(3).

ARMA(1,1) model je malo lošiji od AR(1) modela, no svakako puno bolji od MA(3) modela.

Na osnovu grafa na kojem sam prikazala AR(1), MA(3) i ARIMA(1,1) zaključujem da je najbolji fit AR(1) model čije su koeficijenti navedeni u nastavku.

$$X_t = -41.751 + 0.919 \cdot X_{t-1} + Z_t,$$

$$Z_t \sim WN(0, \sigma^2), \quad \sigma^2 = 235050.3$$

On ujedno ima i najniži AIC i BIC kriterij od svih navedenih modela koji su dobiveni koristeći iste procedure u R-u radi lakše usporedbe modela.

Također, koristeći Lagrange-Multiplier test

ustanovila smo heteroskedastičnost u AR(1) modelu što daje naslutiti dobar fit za GARCH(1,1) što sam potvrdila i grafički.

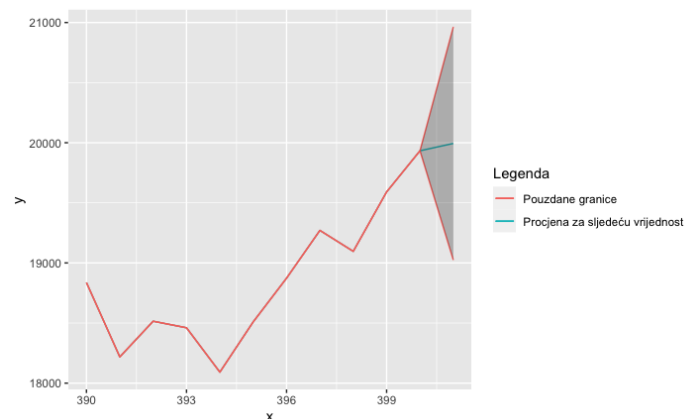
Naziv modela	AIC kriterij	BIC kriterij
AR(1)	6090.045	6102.019
AR(2)	6092.035	6108
AR(3)	6092.865	6112.822
MA(1)	6498.106	6510.081
MA(2)	6316.994	6332.96
MA(3)	6260.702	6280.66
ARMA(1,1)	6092.034	6108

Tablica 1. Dobiveni AIC i BIC kriteriji modela

Na kraju, vrijednost sljedeće predviđene vrijednosti modelom AR(1) glasi 19 994.12 , dok 95 % pozudan interval za nju iznosi [19024.48 , 20963.76].



Slika 7. Prilagodba podataka GARCH(1,1) modelu



Slika 8. Prikaz predviđane vrijednosti te 95% pouzdanog intervala za nju